FIAP · PÓS-TECH IA PARA DEVS · FASE 1

Tech Challenge — Classificação de Câncer de Mama

Diagnóstico maligno × benigno com KNN, SVM e Random Forest

Integrantes

Hugo César Coelho de Oliveira — RM 377261

Anna Beatriz de Araujo Bonfim — RM 377312

Guilherme Aguiar de Oliveira Junior — RM 374357

Igor Katzer de Sá — RM 377718

Thiago Romão Monteiro Pacheco Prado — RM 378536

Outubro de 2026

1. Links da entrega

Repositório Git	https://github.com/hugocesarcoelho/fiap-tc-fase1-ai
Vídeo de demonstração (parte 1)	https://youtu.be/vv8gxPOWYq0 · análise exploratória, pré-processamento e modelos (notebook principal)
Vídeo de demonstração (parte 2)	https://youtu.be/FOKu4TnUH_s · execução via Docker, validação, 10 vs 30 variáveis e SHAP (notebook 02)
Dataset	Incluído em `data/data.csv` · original: Kaggle — Breast Cancer Wisconsin (Diagnostic)

2. Conteúdo do repositório

Entregável	Onde está
Código-fonte completo	`breast-cancer-knn-svm-random-forest.ipynb` — análise exploratória, pré-processamento, treino e avaliação dos três modelos. `02-validacao-shap.ipynb` — conjunto de validação, comparação entre 10 e 30 variáveis e interpretação com SHAP
Dockerfile e README.md com instruções de execução	`Dockerfile` — imagem Python 3.12 com as dependências, os dois notebooks e o dataset, servindo o Jupyter na porta 8888. `README.md` — execução com Docker ou com ambiente virtual (`requirements.txt` com versões fixadas)
Dataset	`data/data.csv` (569 exames, 32 colunas)
Resultados (prints, gráficos e análises)	Saídas salvas nos notebooks e imagens em `docs/resultados/` e `docs/figuras/` ; seção 4 deste documento
Relatório técnico	`docs/relatorio-tecnico.md` e `docs/relatorio-tecnico.pdf` ; seção 5 deste documento

3. Como executar

Com Docker

```
git clone https://github.com/hugocesarcoelho/fiap-tc-fase1-ai.git
cd fiap-tc-fase1-ai
docker build -t fiap-tc-fase1-ai .
docker run --rm -p 8888:8888 fiap-tc-fase1-ai
```

Abra **http://localhost:8888**, entre em `breast-cancer-knn-svm-random-forest.ipynb` e execute todas as células (**Run All**). Depois faça o mesmo em `02-validacao-shap.ipynb`.

Sem Docker (Python 3.11+)

```
git clone https://github.com/hugocesarcoelho/fiap-tc-fase1-ai.git
cd fiap-tc-fase1-ai
python -m venv .venv
.venv\Scripts\Activate.ps1        # Linux/macOS: source .venv/bin/activate
pip install -r requirements.txt
jupyter notebook breast-cancer-knn-svm-random-forest.ipynb
```

Execute todas as células (**Run All**) e depois repita com `02-validacao-shap.ipynb`. Os notebooks leem o dataset pelo caminho relativo `data/data.csv`, então devem ser abertos a partir da raiz do projeto.

4. Resultados obtidos

4.1 Desempenho dos modelos (conjunto de teste, 114 exames)

Métrica	KNN (k = 5)	SVM linear	Random Forest
Acurácia	**92,1%**	**92,1%**	88,6%
Recall de malignos	**85,7%** (36 de 42)	83,3% (35 de 42)	76,2% (32 de 42)
Precisão de malignos	92,3%	**94,6%**	91,4%
F1 de malignos	**0,889**	0,886	0,831
Falsos negativos	**6**	7	10
Falsos positivos	3	**2**	3

Matrizes de confusão e métricas por classe, da célula de comparação do notebook, lado a lado (classe 1 = maligno):

```
KNN                          SVM                          Random Forest
[[69  3]                     [[70  2]                     [[69  3]
 [ 6 36]]                     [ 7 35]]                     [10 32]]
   precision recall  f1         precision recall  f1        precision recall  f1
0    0.920  0.958  0.939     0    0.909  0.972  0.940     0    0.873  0.958  0.914
1    0.923  0.857  0.889     1    0.946  0.833  0.886     1    0.914  0.762  0.831
accuracy           0.921     accuracy           0.921     accuracy           0.886
```

4.2 Escolha do k e importância das variáveis

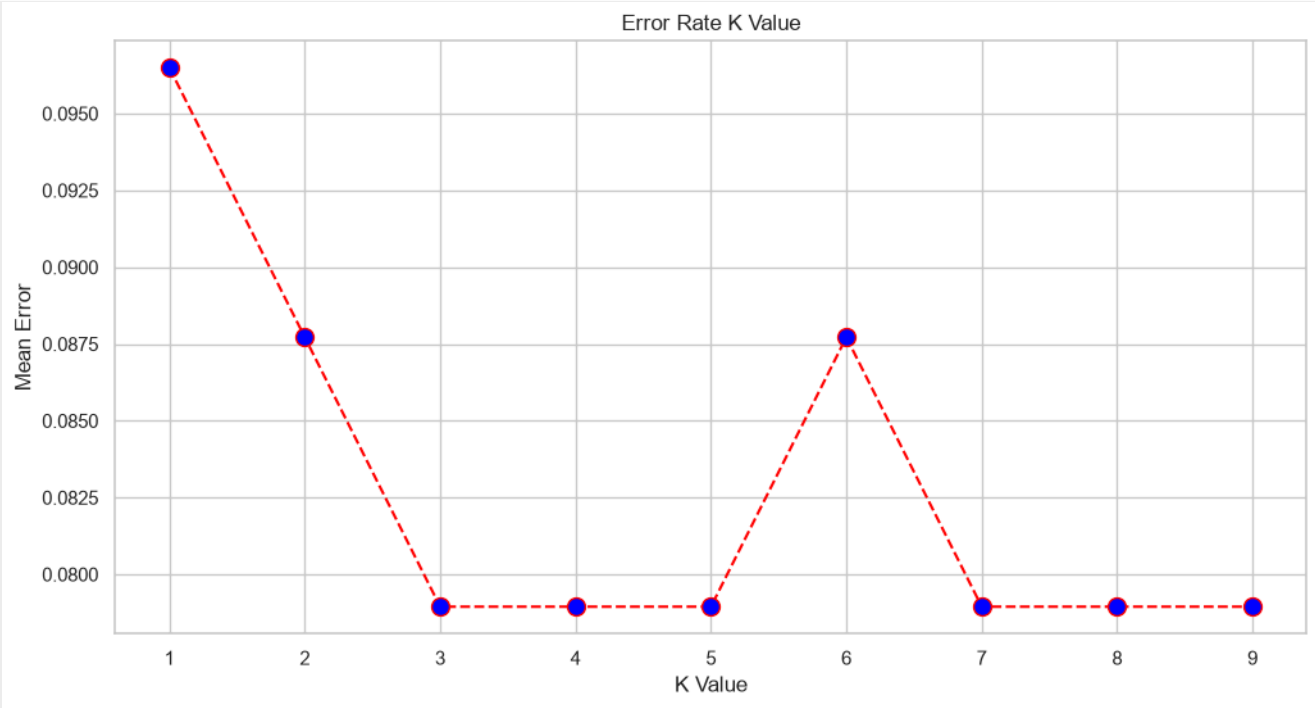


Figura 1. Taxa de erro do KNN no teste para k de 1 a 9. Escolhido k = 5.

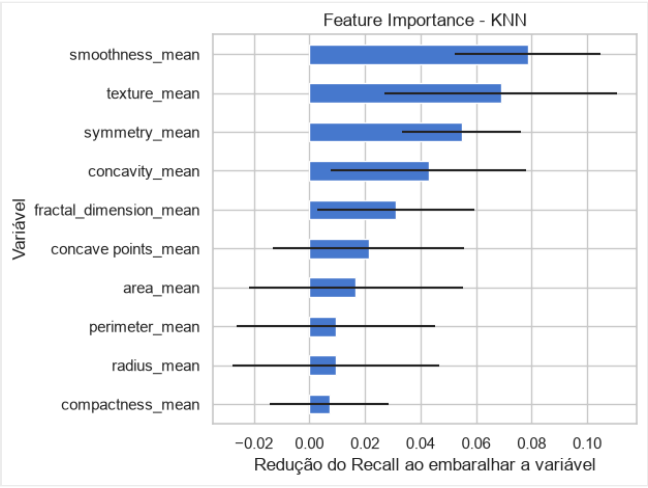


Figura 2. Importância das variáveis no KNN por permutação (queda do recall de malignos).

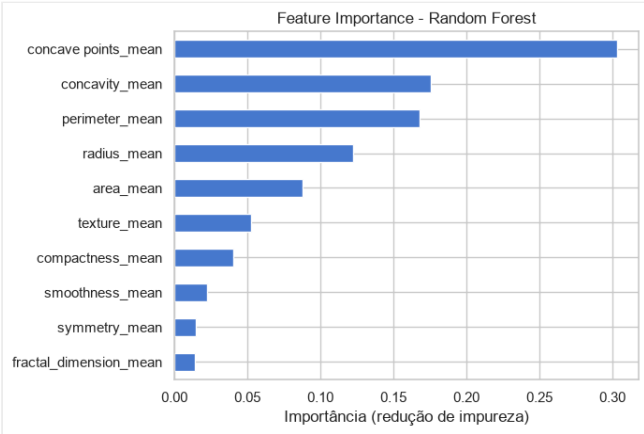


Figura 3. Importância das variáveis no Random Forest (redução de impureza).

4.3 Análise exploratória

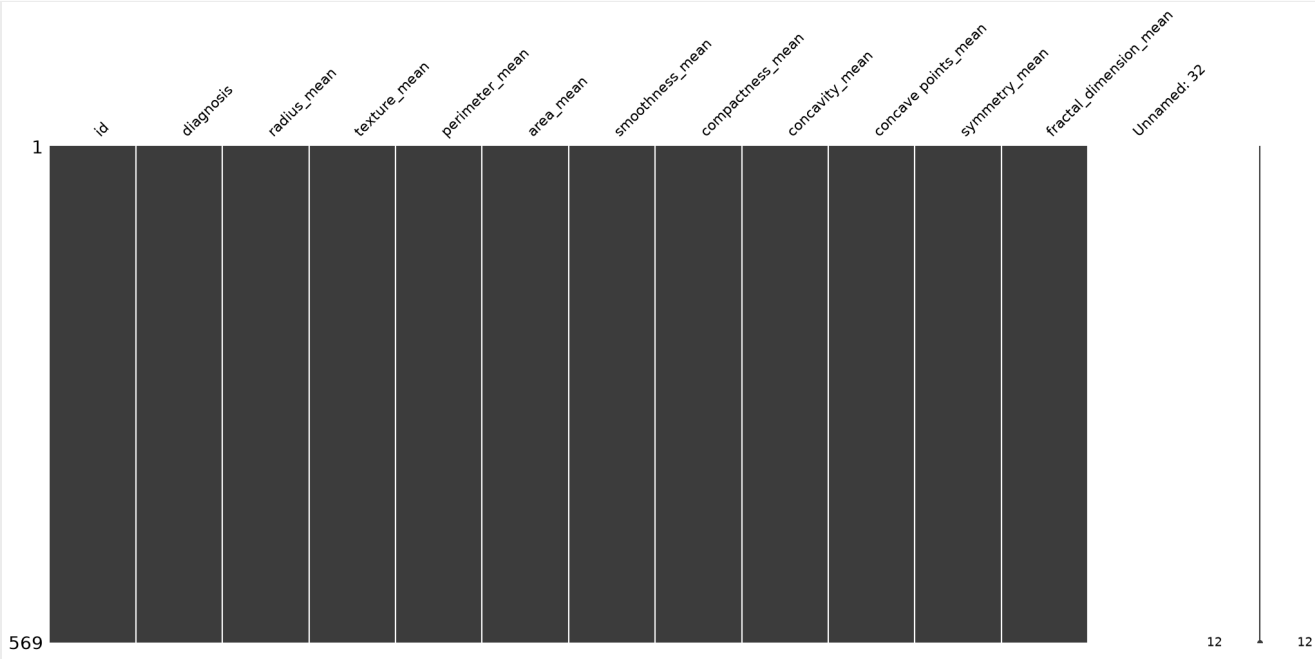


Figura 4. Matriz de valores ausentes (missingno): nenhuma medida tem valores faltantes; só a coluna `Unnamed: 32` é vazia.

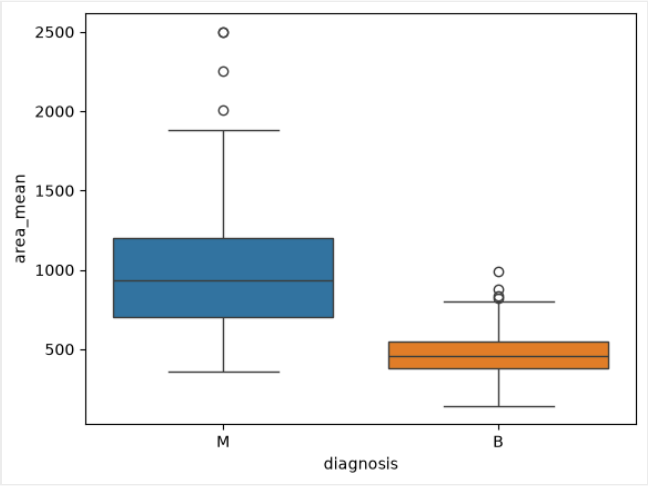


Figura 5. `area_mean` por diagnóstico (B = benigno, M = maligno).

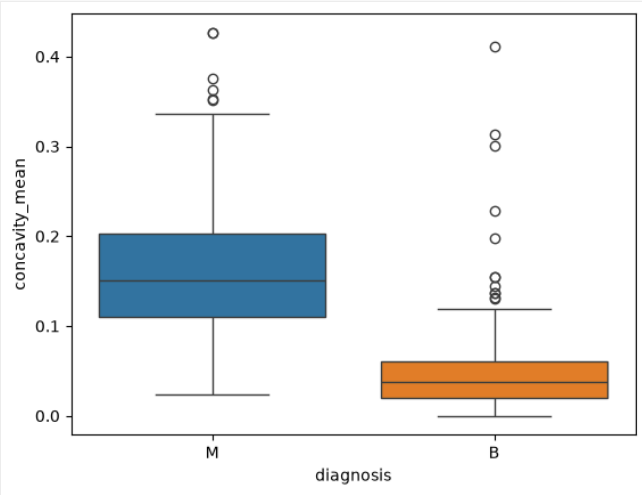


Figura 6. `concavity_mean` por diagnóstico.

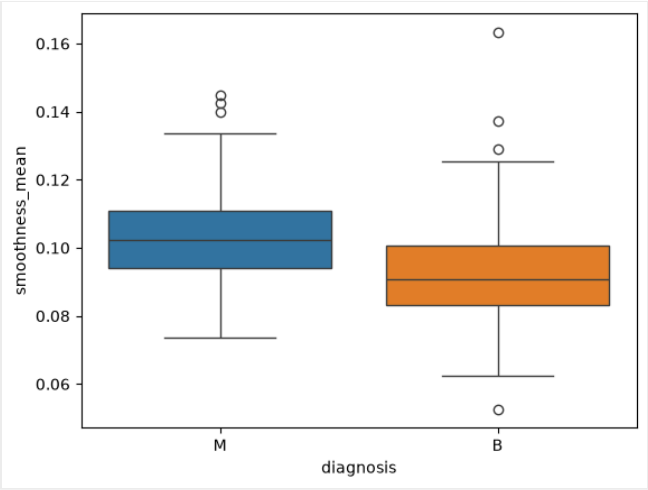


Figura 7. `smoothness_mean` por diagnóstico.

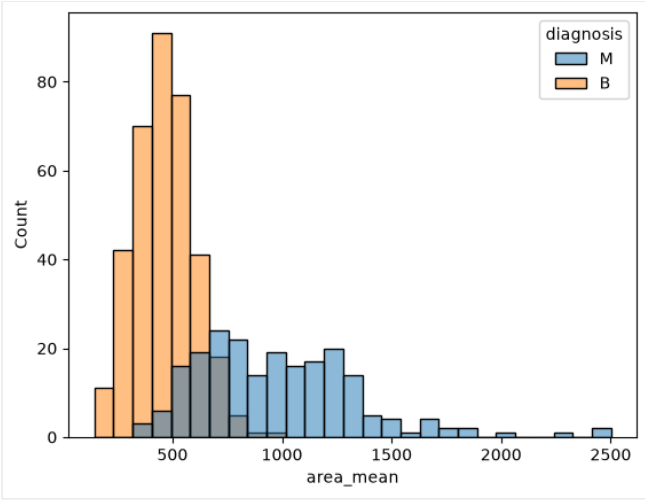


Figura 8. Histograma de `area_mean` por diagnóstico.

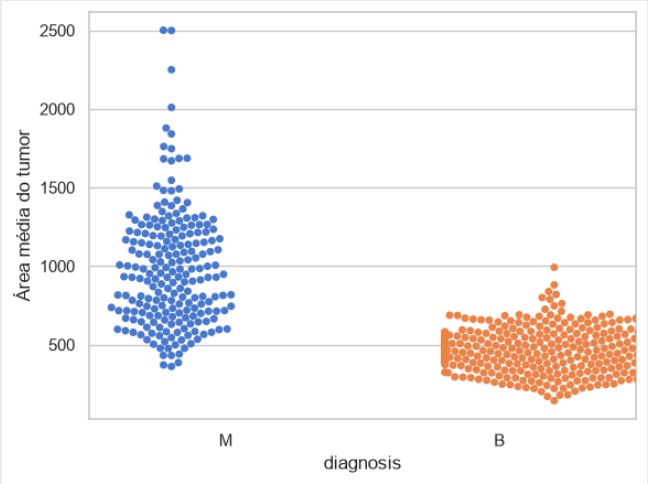


Figura 9. Swarmplot da área média do tumor por diagnóstico.

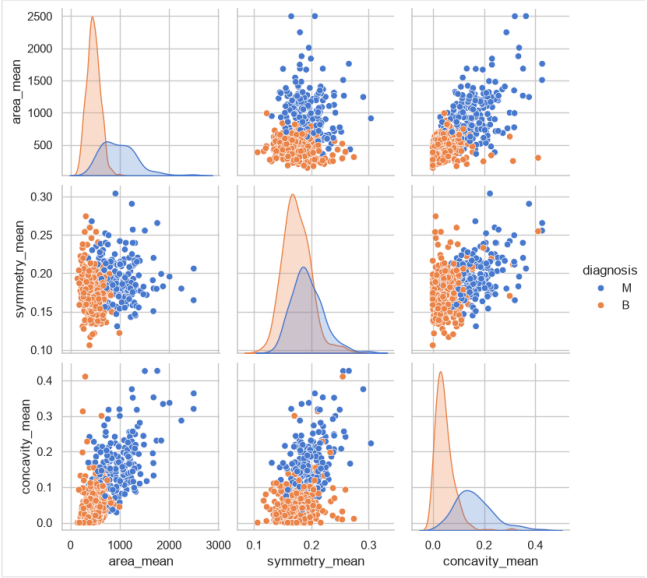


Figura 10. Pairplot de área, simetria e concavidade: área × concavidade separa bem as classes.

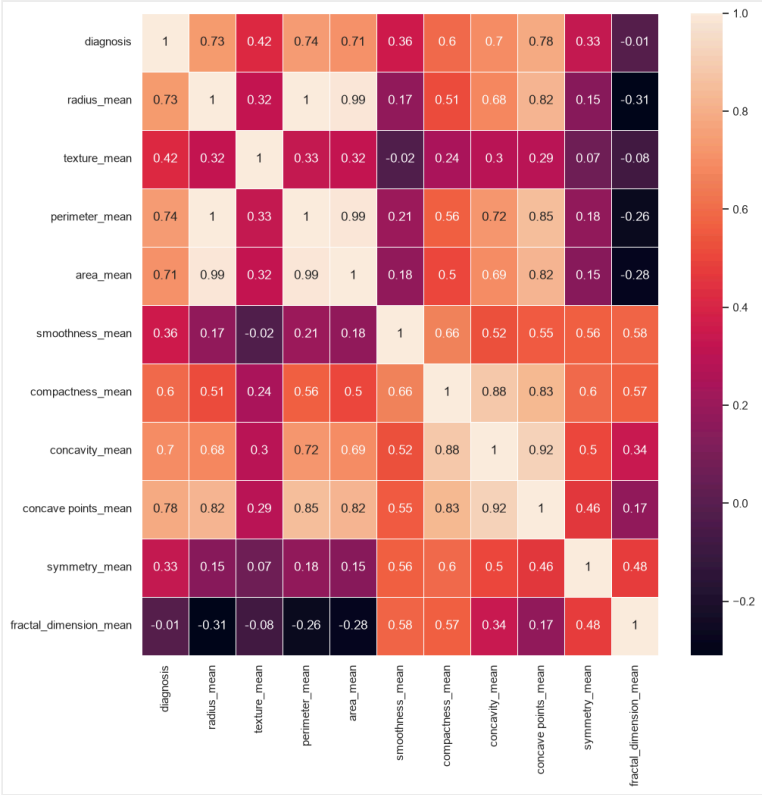


Figura 11. Matriz de correlação das 10 variáveis médias e do diagnóstico.

4.4 Validação, 30 variáveis e SHAP (conjunto de teste, 86 exames)

Resultados do `02-validacao-shap.ipynb`, com hiperparâmetros escolhidos num conjunto de validação separado (treino 398, validação 85, teste 86).

Variáveis	Modelo	Configuração (validação)	Acurácia	Recall malignos	Precisão	F1	FN	FP
10 (`_mean`)	KNN	k = 5	90,7%	90,6%	85,3%	0,879	3	5
10 (`_mean`)	SVM linear	C = 0,1	91,9%	84,4%	93,1%	0,885	5	2
10 (`_mean`)	Random Forest	100 árvores	87,2%	78,1%	86,2%	0,820	7	4
30 (todas)	KNN	k = 3	95,3%	90,6%	96,7%	0,935	3	1
30 (todas)	**SVM linear**	**C = 1**	**95,3%**	**93,8%**	**93,8%**	**0,938**	**2**	**2**
30 (todas)	Random Forest	100 árvores	90,7%	81,2%	92,9%	0,867	6	2

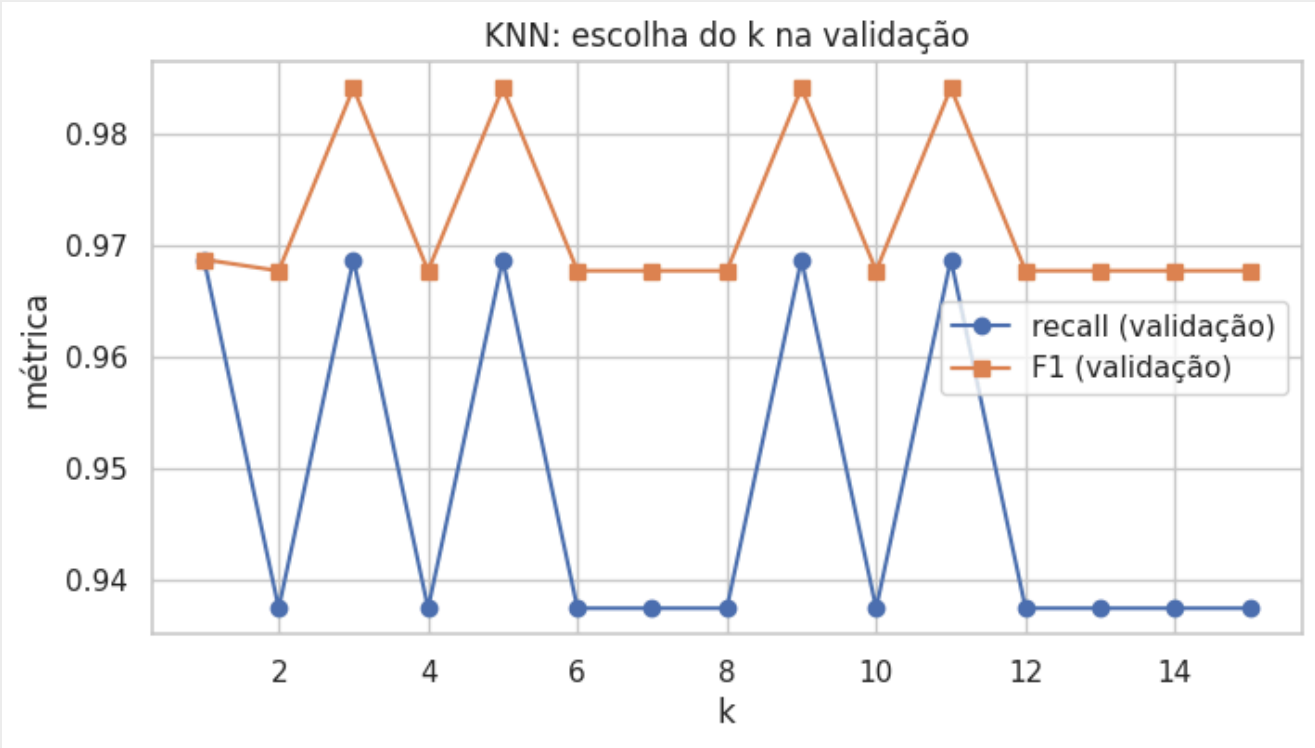


Figura 12. Recall e F1 do KNN na validação (30 variáveis) para k de 1 a 15. Escolhido k = 3.

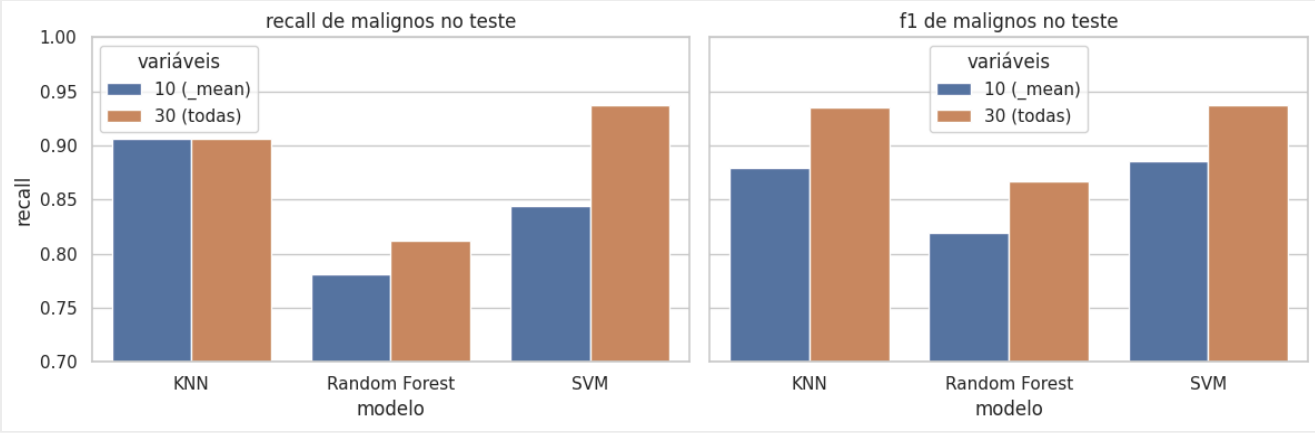


Figura 13. Recall e F1 de malignos no teste com 10 e com 30 variáveis.

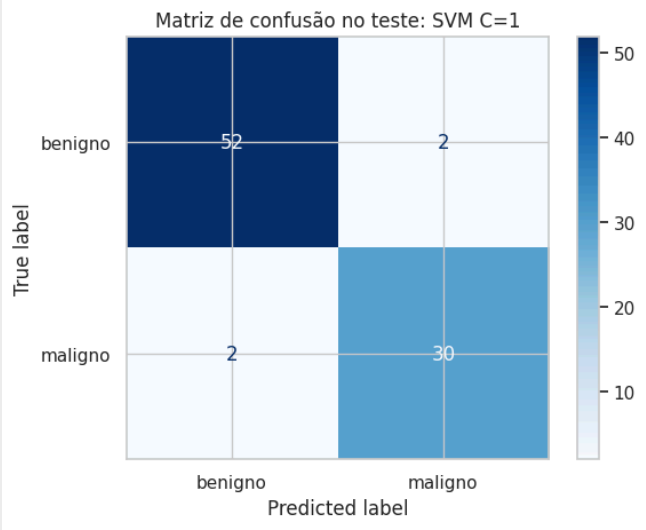


Figura 14. Matriz de confusão do SVM linear (C = 1, 30 variáveis) no teste: 2 falsos negativos e 2 falsos positivos.

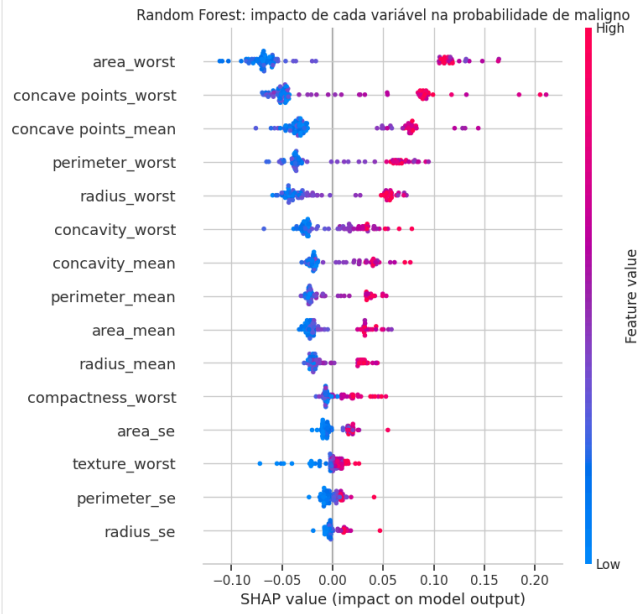


Figura 15. SHAP no Random Forest: impacto de cada variável na probabilidade de maligno.

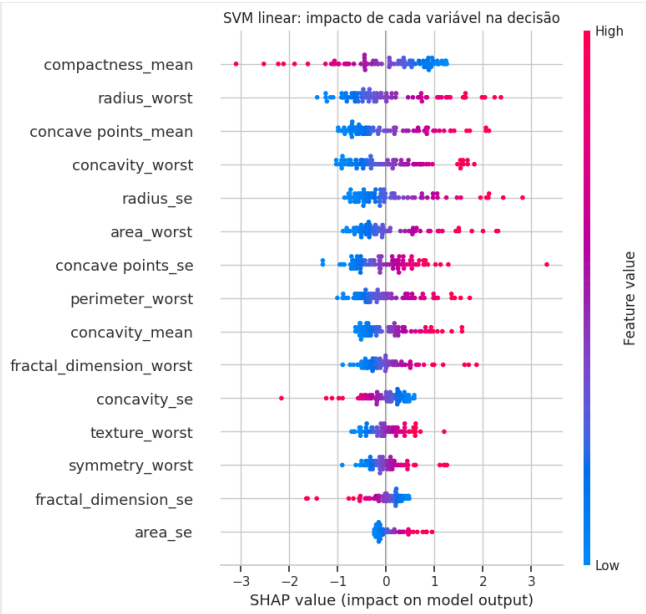


Figura 16. SHAP no SVM linear: impacto de cada variável na decisão.

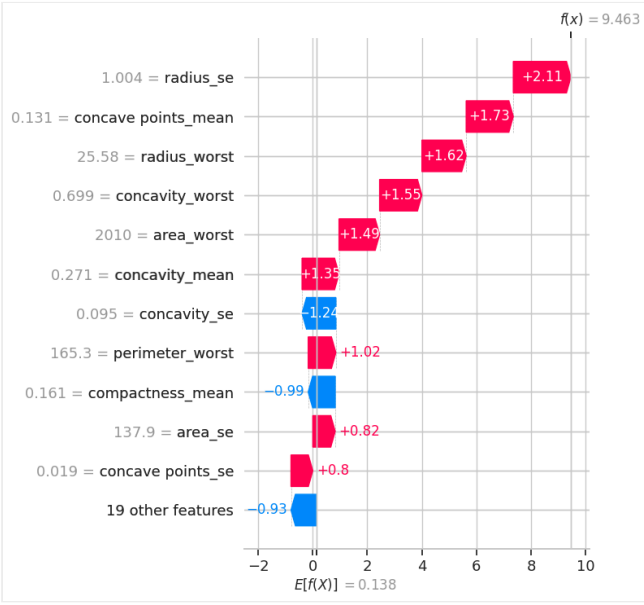


Figura 17. SHAP de um exame maligno do teste (waterfall): contribuição de cada medida para a decisão do SVM.

5. Relatório técnico

As figuras citadas estão na seção 4.

Introdução

O KNN (k = 5) e o SVM linear acertaram 92,1% dos casos de teste (105 de 114 tumores); o Random Forest acertou 88,6%. O KNN é o recomendado, por encontrar mais casos de câncer: 36 de 42 malignos.

Depois, com um conjunto de validação separado e as 30 variáveis, o SVM linear (C = 1) passou a ser o recomendado: 95,3% de acurácia e 2 falsos negativos em 32 malignos, num teste de 86 exames (seção "Validação, 30 variáveis e SHAP").

O trabalho é o Tech Challenge da Fase 1 da pós-graduação IA para DEVs (FIAP). O objetivo é apoiar o diagnóstico de câncer de mama com um classificador binário: maligno (M) ou benigno (B).

Os dados vêm do Breast Cancer Wisconsin (Diagnostic). São 569 exames, 357 benignos (62,7%) e 212 malignos (37,3%). Cada exame tem 30 medidas do núcleo celular, extraídas de imagens de punção aspirativa por agulha fina. O código está no repositório do projeto.

Estratégias de pré-processamento

Os dados vieram limpos: só foi preciso escolher colunas, codificar o alvo, dividir treino e teste e padronizar a escala.

1. **Seleção de variáveis.** Cada medida aparece em três versões: média (`_mean`), erro padrão (`_se`) e pior valor (`_worst`). Mantivemos só as 10 médias. As versões `_worst` são muito correlacionadas com as médias, e as `_se` medem variação, não tamanho ou forma. Com menos colunas, o KNN sofre menos com dimensão alta e o modelo fica mais fácil de explicar.
2. **Valores ausentes.** A matriz do `missingno` e o `isnull().sum()` mostraram zero ausentes nas medidas. A única coluna vazia, `Unnamed: 32` (569 nulos), é um artefato do CSV e foi removida, junto com o `id`, que não tem valor preditivo. Também não há exames duplicados, valores negativos nem rótulos fora de M e B. Os 13 exames com concavidade zero são todos benignos, com o zero nas colunas de concavidade e de pontos côncavos ao mesmo tempo: indicam contorno liso, não dado faltando, e foram mantidos.
3. **Codificação do alvo.** `diagnosis` virou numérica: maligno = 1, benigno = 0. Assim a classe positiva é a doença, e o recall mede quantos casos de câncer o modelo encontra.

4. **Divisão treino/teste.** 80% para treino (455 exames) e 20% para teste (114), com `stratify=y` e `random_state=7`. A estratificação mantém a proporção de cerca de 37% de malignos nas duas partes: 170 de 455 no treino e 42 de 114 no teste.
5. **Padronização.** `StandardScaler` deixa cada variável com média 0 e desvio 1. Sem isso, `area_mean` (centenas a milhares) dominaria a distância do KNN sobre `smoothness_mean` (cerca de 0,1). O scaler foi ajustado só no treino e depois aplicado ao teste, para evitar vazamento de dados.

A análise exploratória (boxplots, histograma, swarmplot e pairplot) orientou essas escolhas. Ela mostrou que tumores malignos têm área e concavidade maiores, enquanto a simetria quase não separa os grupos.

Modelos usados e por quê

Comparamos três classificadores de natureza diferente: um baseado em vizinhança (KNN), um em fronteira linear (SVM) e um conjunto de árvores de decisão (Random Forest). KNN e SVM usaram os dados padronizados. O Random Forest usou os dados originais, porque árvores não dependem da escala.

Modelo	Configuração	Por que foi escolhido
KNN (`KNeighborsClassifier`)	k = 5, distância euclidiana	Simples e sem suposição sobre a forma dos dados. Classifica pelo diagnóstico dos 5 exames mais parecidos, o que é fácil de explicar. Funciona bem com poucas variáveis contínuas já padronizadas.
SVM linear (`LinearSVC`)	C = 1	O pairplot mostrou que as classes se separam razoavelmente por uma fronteira (área e concavidade altas = maligno). O SVM busca a fronteira de maior margem e costuma generalizar bem em bases pequenas como esta (455 exames de treino).
Random Forest (`RandomForestClassifier`)	100 árvores, `random_state=42`	Capta relações não lineares e interações entre variáveis sem exigir padronização. Por combinar muitas árvores, é robusto a ruído e tem uma importância de variáveis própria, que serve de contraponto à do KNN.

Escolha do k. Testamos k de 1 a 9 e medimos a taxa de erro no teste. O erro cai de 9,6% (k = 1) para 7,9% em k = 3, 4 e 5, sobe para 8,8% em k = 6 e volta a 7,9% de k = 7 a 9. Escolhemos

k = 5, dentro da faixa de erro mínimo: um k ímpar evita empate entre as duas classes, e um k maior reduz a sensibilidade a exames atípicos.

Além do k do KNN, nenhum hiperparâmetro foi ajustado: o `C` do SVM e o número de árvores do Random Forest ficaram nos valores padrão.

Resultados e interpretação

KNN e SVM empataram em acurácia (92,1%), mas o KNN encontrou um câncer a mais: recall de 85,7% contra 83,3% do SVM. O Random Forest ficou em último nas duas métricas, com 88,6% de acurácia e 76,2% de recall.

Métrica (teste, 114 exames)	KNN (k = 5)	SVM linear	Random Forest
Acurácia	92,1%	92,1%	88,6%
Recall de malignos	85,7% (36 de 42)	83,3% (35 de 42)	76,2% (32 de 42)
Precisão de malignos	92,3%	94,6%	91,4%
F1 de malignos	0,889	0,886	0,831
Falsos negativos (maligno previsto como benigno)	6	7	10
Falsos positivos (benigno previsto como maligno)	3	2	3

Todos os números vêm do notebook: a acurácia de cada modelo e, na célula de comparação, a matriz de confusão e o relatório de classificação dos três.

Por que o recall importa mais que a acurácia. Num exame de triagem, um falso negativo manda para casa uma paciente com câncer; um falso positivo gera um exame a mais. Por isso o KNN é o modelo preferido aqui: tem a mesma acurácia do SVM e o maior recall dos três. Ainda assim, 6 de 42 malignos escapam, e esse é o principal ponto a melhorar.

Por que o Random Forest ficou atrás. Com 455 exames de treino e 10 variáveis bem correlacionadas, ele não teve vantagem sobre fronteiras mais simples. O modelo concentrou a importância em medidas de contorno e tamanho: `concave points_mean` (30%), `concavity_mean` (18%) e `perimeter_mean` (17%). Sem ajuste de hiperparâmetros nem do limiar de decisão, foi o mais conservador ao prever maligno: 10 falsos negativos, contra 6 do KNN.

Importância das variáveis. No KNN, a importância foi medida por permutação: embaralha-se uma variável e mede-se quanto o recall cai. Textura e forma da célula (suavidade, textura,

simetria) pesam mais que tamanho.

Isso parece contradizer a correlação: `concave points_mean` (0,78), `perimeter_mean` (0,74) e `radius_mean` (0,73) são as mais correlacionadas com o diagnóstico. A explicação é a redundância. Raio, perímetro e área medem quase a mesma coisa, então embaralhar uma delas pouco muda, porque as outras compensam. Os desvios são grandes: em 5 das 10 variáveis a barra cruza o zero, e nenhuma sozinha é decisiva.

Análise exploratória. Os gráficos confirmam o que os modelos aprenderam. Malignos têm `area_mean` e `concavity_mean` claramente maiores, e o par área × concavidade separa bem os grupos no pairplot. Já `symmetry_mean` tem forte sobreposição entre as classes. As estatísticas descritivas mostram o mesmo: a média de `area_mean` dos malignos é o dobro da dos benignos (978 contra 463), a de `concavity_mean` é 3,5 vezes maior, e `fractal_dimension_mean` tem a mesma média nas duas classes.

Validação, 30 variáveis e SHAP

Esta parte vem do notebook `02-validacao-shap.ipynb`. Nele ajustamos os hiperparâmetros sem olhar o teste, testamos as variáveis `_worst` e `_se` e incluímos a interpretação com SHAP pedida no enunciado. As versões das dependências foram fixadas no `requirements.txt`, e o `Dockerfile` sobe o Jupyter com tudo instalado (instruções no README).

Validação e 30 variáveis

No notebook principal, o `k` do KNN foi escolhido pela taxa de erro no teste, o que deixa a métrica final otimista. Desta vez dividimos a base em treino (398 exames), validação (85) e teste (86), com `stratify` e `random_state=7`, e escolhemos os hiperparâmetros pelo maior recall de malignos na validação: `k` de 1 a 15 no KNN, `C` em {0,01; 0,1; 1; 10} no SVM linear e 100 ou 300 árvores, com `class_weight` padrão ou `balanced`, no Random Forest. A padronização ficou dentro do `Pipeline`, ajustada só no treino. Rodamos tudo com as 10 medidas `_mean` e com as 30.

Variáveis	Modelo	Configuração (validação)	Acurácia	Recall malignos	Precisão	F1	FN	FP
10 (`_mean`)	KNN	k = 5	90,7%	90,6%	85,3%	0,879	3	5
10 (`_mean`)	SVM linear	C = 0,1	91,9%	84,4%	93,1%	0,885	5	2
10 (`_mean`)	Random Forest	100 árvores	87,2%	78,1%	86,2%	0,820	7	4
30 (todas)	KNN	k = 3	95,3%	90,6%	96,7%	0,935	3	1
30 (todas)	**SVM linear**	**C = 1**	**95,3%**	**93,8%**	**93,8%**	**0,938**	**2**	**2**
30 (todas)	Random Forest	100 árvores	90,7%	81,2%	92,9%	0,867	6	2

Teste com 86 exames (32 malignos). Os números não se comparam diretamente aos da seção anterior, que usou 114.

Com 10 variáveis, o KNN escolheu `k = 5` de novo, então a conclusão do notebook principal se mantém. Com 30, todos os modelos melhoram, o que nos surpreendeu. Tínhamos descartado as `_worst` por parecerem redundantes com as médias, mas elas registram o pior valor de cada característica, e um tumor com um núcleo muito irregular pode ter média próxima à de um benigno. O SVM linear com 30 variáveis é o melhor modelo, com 2 falsos negativos em 32 malignos. Ele chegou a 100% na validação e 95,3% no teste, diferença esperada com 85 exames de validação. O Random Forest ficou atrás nos dois cenários.

SHAP

Usamos `TreeExplainer` no Random Forest e `LinearExplainer` no SVM linear, sobre os dados padronizados. As variáveis de maior impacto combinam tamanho (`radius_worst`, `area_worst`, `perimeter_worst`) e irregularidade do contorno (`concave points_mean`, `concavity_worst`, `compactness_mean`), e metade delas é `_worst`. Em relação à importância por permutação e por impureza da seção anterior, o SHAP mostra também a direção do efeito: valores altos empurram para maligno.

No SVM, `compactness_mean` alta empurra para benigno. Não é que tumores compactos sejam benignos: `concavity` e `concave points` já capturam a irregularidade do contorno, e o coeficiente de `compactness` compensa o excesso, efeito comum de colinearidade em modelos

lineares. No gráfico waterfall de um exame maligno, a decisão vem de várias medidas somadas, principalmente raio, área e pontos côncavos.

As figuras estão na seção 4.4 (Figuras 12 a 17).

Conclusão e próximos passos

Com as 10 medidas médias e a divisão original, o KNN (k = 5) chega a 92,1% de acurácia e 85,7% de recall. Com validação separada e as 30 medidas, o modelo recomendado passa a ser o SVM linear (C = 1), com 95,3% de acurácia, 93,8% de recall e 2 falsos negativos em 32 malignos no teste. A decisão se apoia em tamanho e irregularidade do contorno, com bastante peso das medidas `_worst`.

Mesmo o melhor modelo deixa malignos escaparem, e na triagem um falso negativo custa muito mais que um falso positivo. Por isso o modelo serve para priorizar exames, não para diagnosticar. Daqui em diante, falta ajustar o limiar de decisão a favor do recall e usar validação cruzada estratificada para reduzir a variância das métricas, já que com 86 exames de teste cada erro move a acurácia em 1,2 ponto. Antes de qualquer uso real, também seria preciso validar com dados de outros hospitais e equipamentos, porque os 569 exames vêm de uma única fonte.